

Київський національний університет імені Тараса Шевченка

Факультет комп'ютерних наук і кібернетики

Звіт

з лабораторної роботи №2

з моделювання складних систем

Варіант 4

Виконав:

Студент групи ІПС-31

Вербицький Артем Віталійович

Київ


2024

1. Мета лабораторної роботи

Побудова лінійної моделі з допомогою псевдообернених операторів.

Будемо вважати, що на вхід системи перетворення, математична модель якої невідома, поступають послідовно дані у вигляді $m - 1$ вимірних векторів \mathbf{x}_j .

На виході системи спостерігається сигнал у вигляді вектора \mathbf{y}_j розмірності p .



2. Постановка задачі

Для послідовності вхідних сигналів \mathbf{x}_j , $j = 1, 2, \dots, n$ та вихідних сигналів \mathbf{y}_j , $j = 1, 2, \dots, n$ знайти оператор P перетворення вхідного сигналу у вихідний.

Будемо шукати математичну модель оператора об'єкту в класі лінійних операторів

$$\mathbf{A} \begin{pmatrix} \mathbf{x}_j \\ 1 \end{pmatrix} = \mathbf{y}_j, \quad j = 1, 2, \dots, n. \quad (1)$$

Невідома матриця \mathbf{A} математичної моделі об'єкту розмірності $p \times n$. Систему (1) запишемо у матричній формі

$$\mathbf{A} \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \dots & \mathbf{x}_n \\ 1 & 1 & \dots & 1 \end{pmatrix} = (\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n),$$

або

$$\mathbf{A}\mathbf{X} = \mathbf{Y}, \quad (2)$$

де $\mathbf{X} = \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \dots & \mathbf{x}_n \\ 1 & 1 & \dots & 1 \end{pmatrix}$ – матриця вхідних сигналів розмірності $m \times n$,

$\mathbf{Y} = (\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n)$ – матриця вихідних сигналів розмірності $p \times n$.

Матрицю \mathbf{X} будемо інтерпретувати як двовимірне вхідне зображення, а матрицю \mathbf{Y} вихідне зображення.

Тоді

$$\mathbf{A} = \mathbf{Y}\mathbf{X}^+ + \mathbf{V}\mathbf{Z}^T(\mathbf{X}^T),$$

де матриця

$$\mathbf{V} = \begin{pmatrix} \mathbf{v}_{(1)}^T \\ \mathbf{v}_{(2)}^T \\ \vdots \\ \mathbf{v}_{(p)}^T \end{pmatrix},$$

розмірності $p \times m$, $Z(X^T) = I_m - XX^+$.

- **Формула Гревіля для псевдообернення матриці:**

Якщо для матриці A відома псевдообернена (обернена) матриця A^+ , то для розширеної матриці $\begin{pmatrix} A \\ a^T \end{pmatrix}$ справедлива формула

$$\begin{pmatrix} A \\ a^T \end{pmatrix}^+ = \begin{cases} \left(A^+ - \frac{Z(A)aa^T A^+}{a^T Z(A)a} : \frac{Z(A)a}{a^T Z(A)a} \right), & \text{if } a^T Z(A)a > 0 \\ \left(A^+ - \frac{R(A)aa^T A^+}{1 + a^T R(A)a} : \frac{R(A)a}{1 + a^T R(A)a} \right), & \text{if } a^T Z(A)a = 0 \end{cases},$$

де $Z(A) = E - A^+ A$, $R(A) = A^+ (A^+)^T$.

Для першого кроку алгоритму $(a_1^T)^+ = \frac{a_1}{a_1^T a_1}$, де $A = \begin{pmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_n^T \end{pmatrix}$.

- **Формула Мура - Пенроуза для знаходження оберненої (псевдооберненої) матриці:**

$$A^+ = \lim_{\delta^2 \rightarrow 0} \left\{ (A^T A + \delta^2 E_n)^{-1} A^T \right\} = \lim_{\delta^2 \rightarrow 0} \left\{ A^T (A A^T + \delta^2 E_m)^{-1} \right\}.$$

матриця A розмірності $m \times n$.

Вхідний сигнал – x1.bmp, вихідний сигнал – y4.bmp.

3. Хід роботи

Програмна реалізація виконана мовою Python. Програма розділена на три файли: **MCS_Lab_2.py** – основний, **PseudoInverseMatrixMethods.py** – з методами знаходження псевдо-обернених матриць, **OperationsCounter.py** – з методами обрахунку кількості операцій.

Почнемо з ініціалізації всіх необхідних параметрів, а саме зчитуємо вхідне та вихідне зображення й побудуємо відповідні матриці, з якими надалі працюватимемо. Також одразу створимо оригінальне вихідне зображення у форматі png:

```
def main():  
    X = readImage('x1.bmp')  
    Y = readImage('y4.bmp')  
  
    m = X.shape[1]  
    X = np.vstack((X, np.ones((1, m))))  
  
    saveImage(Y, 'original_Y.png')  
  
    results = {}
```

```
def saveImage(X_, filename):  
    results_dir = 'results'  
    if not os.path.exists(results_dir):  
        os.makedirs(results_dir)  
  
    filepath = os.path.join(results_dir, filename)  
    plt.figure(figsize=(10, 10))  
    plt.imshow(X_, cmap='gray')  
    plt.axis('off')  
    plt.savefig(filepath, bbox_inches='tight', pad_inches=0)  
    plt.close()
```

```
def readImage(filename):
    X = imageio.imread(filename)
    return np.array(X)
```

Шукаємо обернені матриці оригінальним методом Мура-Пенроуза та з застосуванням градієнтного спуску, отримуємо вихідні зображення отримані цими методами та обраховуємо час виконання, використану пам'ять, кількість операцій та похибки відносно оригінального вихідного зображення:

```
# Moore-Penrose method (original)
A_MP, time_MP, memory_MP, ops_MP = calculateOperator(X, Y, pimm.pseudoInverseMatrix_MoorePenrose, oc.count_operations_moo
Y_MP = applyOperator(X, A_MP)
error_norm_MP, mse_MP, rmse_MP = calculateError(Y, Y_MP)

# Moore-Penrose method (gradient descent)
A_MP_GD, time_MP_GD, memory_MP_GD, ops_MP_GD = calculateOperator(X, Y, pimm.pseudoInverseMatrix_MoorePenrose_GradientDesc
Y_MP_GD = applyOperator(X, A_MP_GD)
error_norm_MP_GD, mse_MP_GD, rmse_MP_GD = calculateError(Y, Y_MP_GD)
```

Порівнюємо похибки обох методів та обираємо точніший:

```
# Compare and choose the better Moore-Penrose result
if rmse_MP < rmse_MP_GD:
    saveImage(Y_MP, 'moore_penrose_result.png')
    best_MP = {
        'method': 'Moore-Penrose',
        'time': time_MP,
        'memory': memory_MP,
        'operations': ops_MP,
        'error_norm': error_norm_MP,
        'mse': mse_MP,
        'rmse': rmse_MP
    }
else:
    saveImage(Y_MP_GD, 'moore_penrose_result.png')
    best_MP = {
        'method': 'Gradient Descent',
        'time': time_MP_GD,
        'memory': memory_MP_GD,
        'operations': ops_MP_GD,
        'error_norm': error_norm_MP_GD,
        'mse': mse_MP_GD,
        'rmse': rmse_MP_GD
    }
```

Зберігаємо отримані дані у масив results, аби в подальшому створити JSON:

```
results['Moore-Penrose'] = {
    'time': time_MP,
    'memory': memory_MP,
    'operations': ops_MP,
    'error_norm': error_norm_MP,
    'mse': mse_MP,
    'rmse': rmse_MP
}

results['Gradient Descent'] = {
    'time': time_MP_GD,
    'memory': memory_MP_GD,
    'operations': ops_MP_GD,
    'error_norm': error_norm_MP_GD,
    'mse': mse_MP_GD,
    'rmse': rmse_MP_GD
}

results['Best Moore-Penrose'] = best_MP
```

Аналогічні дії (окрім порівняння) робимо для методів Гревілья та Сингулярного розкладу матриці:

```
# Greville method
A_G, time_G, memory_G, ops_G = calculateOperator(X, Y, pimm.pseudoInverseMatrix_Greville, oc.count_operations_greville, e
Y_G = applyOperator(X, A_G)
saveImage(Y_G, 'greville_result.png')
error_norm_G, mse_G, rmse_G = calculateError(Y, Y_G)
results['Greville'] = {
    'time': time_G,
    'memory': memory_G,
    'operations': ops_G,
    'error_norm': error_norm_G,
    'mse': mse_G,
    'rmse': rmse_G
}

# SVD method
A_SVD, time_SVD, memory_SVD, ops_SVD = calculateOperator(X, Y, pimm.pseudoInverseMatrix_SVD, oc.count_operations_svd, eps
Y_SVD = applyOperator(X, A_SVD)
saveImage(Y_SVD, 'svd_result.png')
error_norm_SVD, mse_SVD, rmse_SVD = calculateError(Y, Y_SVD)
results['SVD'] = {
    'time': time_SVD,
    'memory': memory_SVD,
    'operations': ops_SVD,
    'error_norm': error_norm_SVD,
    'mse': mse_SVD,
    'rmse': rmse_SVD
}
```

Конвертуємо отримані дані та створюємо JSON файл, який використаємо для звіту в html форматі:

```
# Convert NumPy types to Python native types
results = {k: {kk: numpy_to_python(vv) for kk, vv in v.items()} for k, v in results.items()}

# Save results to a JSON file
with open('results.json', 'w') as f:
    json.dump(results, f, indent=2)
```

4. Аналіз результатів

Порівнявши оригінальний метод Мура-Пенроуза та з використанням Градієнтного спуску (**Рис. 1**) спостерігаємо, що другий є швидшим та менш затратним у плані пам'яті. При цьому кількість операцій суттєво більша, ніж в оригінального методу. Точність зображення ж ідентична, тож обираємо метод з використанням Градієнтного спуску для подальшого аналізу.

Moore-Penrose vs Gradient Descent Comparison

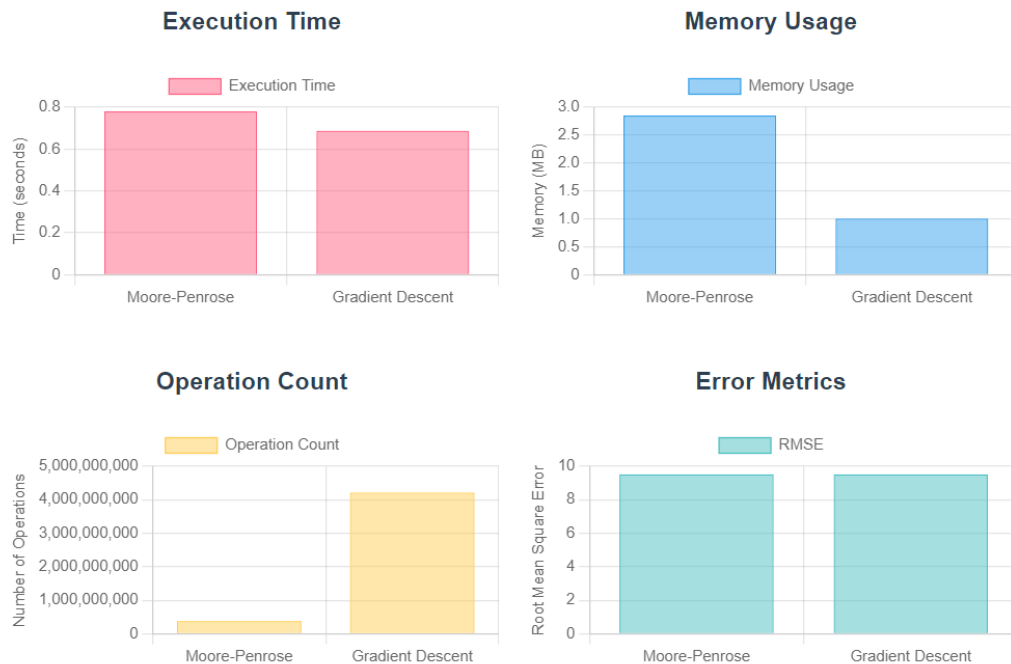


Рис. 1

Отож, на виході (**Рис. 2**) маємо три зображення: оригінальне, знайдене методом Градієнтного спуску та Гревілья:



Рис. 2

З отриманих графіків (Рис. 3) можемо побачити, що метод Сингулярного розкладу матриці значно поступається по швидкості, проте має значну перевагу у кількості використаної пам'яті. Значно виділяється метод Градієнтного спуску по кількості операцій, а також метод Гревілья по використанню пам'яті. Щодо точності знайдених матриць, то результати виявились ідентичними.

Performance Comparison (Gradient Descent, Greville, and SVD)

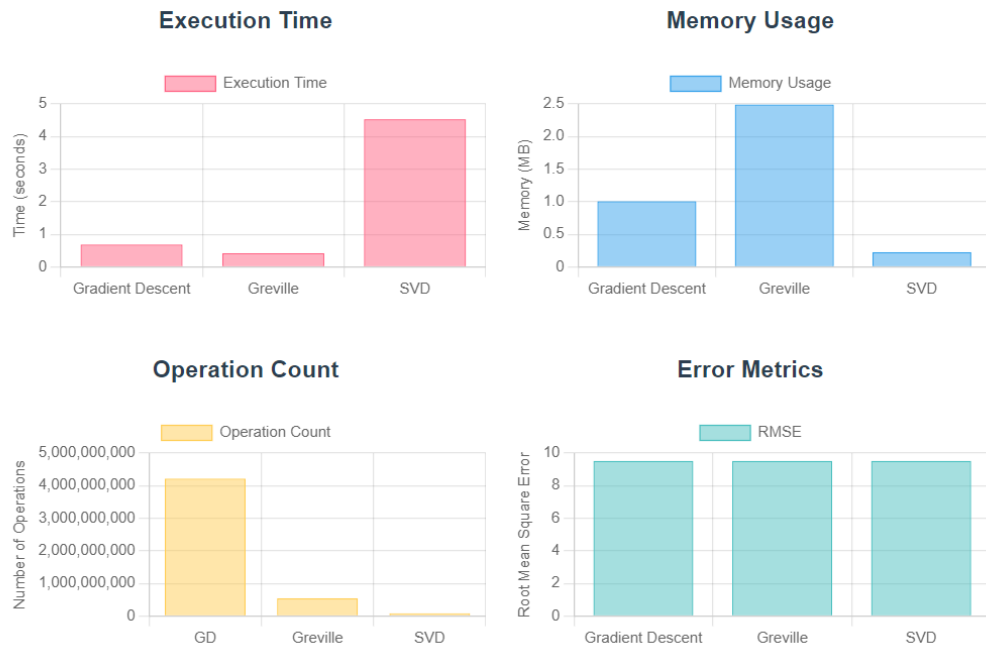


Рис. 3

5. Висновки

Отож, ми реалізували різні алгоритми знаходження псевдообернених операторів для побудови лінійної моделі на прикладі графічних зображень.

У ході роботи ми вияснили, що метод Мура-Пенроуза має широкий потенціал для оптимізації й застосування Градієнтного спуску – один з варіантів, який для цього можна застосувати.

Також ми з'ясували, що кожен метод має певні переваги та недоліки, хоч точність перетворень у нашому випадку виявилась ідентичною. Тож вибір конкретного методу залежить від наявних ресурсів та їхнього розподілу, який ми можемо забезпечити.